

机器人路径规划的快速扩展随机树算法综述

陈秋莲, 蒋环宇, 郑以君

广西大学 计算机与电子信息学院, 南宁 530004

摘 要: 路径规划是移动机器人的重要研究内容。快速扩展随机树(Rapidly-Exploring Random Tree, RRT)算法因在机器人路径规划中的成功应用, 自提出以来就得到了极大的研究与发展。快速扩展随机树作为一种新颖的随机节点采样算法, 相对传统路径规划算法, 具有建模时间短、搜索能力强、方便添加非完整约束等优点。介绍了快速扩展随机树算法的基本原理与性质, 并从单向随机树扩展、多向随机树扩展、其他改进等方面概括了算法的研究现状。最后, 展望了算法未来的研究方向与挑战。

关键词: 机器人路径规划; 快速扩展随机树; 随机采样算法; 非完整约束

文献标志码: A **中图分类号:** TP242.6 **doi:** 10.3778/j.issn.1002-8331.1905-0061

陈秋莲, 蒋环宇, 郑以君. 机器人路径规划的快速扩展随机树算法综述. 计算机工程与应用, 2019, 55(16): 10-17.

CHEN Qiulian, JIANG Huanyu, ZHENG Yijun. Summary of rapidly-exploring random tree algorithm in robot path planning. Computer Engineering and Applications, 2019, 55(16): 10-17.

Summary of Rapidly-Exploring Random Tree Algorithm in Robot Path Planning

CHEN Qiulian, JIANG Huanyu, ZHENG Yijun

School of Computer and Electronical Information, Guangxi University, Nanning 530004, China

Abstract: Path planning is a vital research content of mobile robot technology. Rapidly-Exploring Random Tree(RRT) algorithm has been studied and developed since it was proposed because of its successful application in robot path planning. As a novel random node sampling algorithm, compared with traditional algorithms, the rapidly-exploring random tree has the characteristics of short modeling time, robust search ability and convenience to add nonholonomic constraints. This paper introduces the basic principle and properties of the rapidly-exploring random tree algorithm, summarizes the research status of the algorithm from the aspects of single random tree extension, multiple random tree extension and other improvements. Finally, the future research directions and challenges of the algorithm are prospected.

Key words: robot path planning; rapidly-exploring random tree; random sampling algorithm; nonholonomic constraint

1 引言

机器人路径规划旨在通过规划算法, 在有障碍物的工作环境中, 规划出从起点到目标区域满足机器人自身约束条件的无碰撞路径^[1]。在此基础上, 通过某个或某些准则(如规划路径最短, 行走时间最短, 能量消耗最少等)为机器人选择一条最优的运动路径^[2]。

机器人路径规划算法是移动机器人研究的核心内容之一, 它起始于20世纪70年代, 迄今已有大量的研究成果, 为机器人广泛应用做出重大贡献。但是随着工业领域、社会需求的不断发展, 传统的机器人路径规划算

法研究进展缓慢, 难以满足复杂环境下的规划条件。如基于网格分辨率完整性的启发式搜索算法, 需要对全局环境进行完整的网格建模工作^[3-4], 高维环境下的系统开销大; 群智能算法适合整体环境优化, 对问题搜索空间大小的敏感性强, 也不适合高维复杂环境的机器人路径规划^[5]。

基于节点采样的快速扩展随机树(Rapidly-Exploring Random Tree, RRT)算法^[6], 具有障碍物建模简单, 既能用于完整系统的机械臂路径规划, 也能添加约束条件用于非完整系统的轮式机器人或无人机寻路等优点, 为高

基金项目: 国家自然科学基金(No.71371058, No.61363026)。

作者简介: 陈秋莲(1974—), 女, 博士, 副教授, 研究领域为优化计算与CAD; 蒋环宇(1995—), 男, 硕士研究生, 研究领域为路径规划与算法优化, E-mail: 597650532@qq.com; 郑以君(1994—), 男, 硕士研究生, 研究领域为路径规划与算法优化。

收稿日期: 2019-05-07 **修回日期:** 2019-06-21 **文章编号:** 1002-8331(2019)16-0010-08

CNKI网络出版: 2019-06-28, <http://kns.cnki.net/kcms/detail/11.2127.TP.20190626.1751.022.html>

维复杂环境的机器人路径规划开辟了一种新的解决方案。本文从RRT算法的基本原理开始,概述了RRT算法在单向随机树扩展、多向随机树扩展以及其他改进方面的发展现状,列举了改进算法的优缺点,进而展望了算法未来的研究方向与面临的挑战。

2 RRT算法基本原理

2.1 问题描述

设 $X \subseteq \mathbb{R}^n$ 为路径规划问题的有界工作空间,其中 n 表示工作空间维度, $n \in \mathbb{N}$ 且 $n \geq 2$ 。 $X_{obs} \subset X$ 为空间中的障碍区域,空闲区域为 X_{free} ,满足 $X_{free} = X \setminus X_{obs}$, X_{free} 包含工作空间的所有状态点集合。给定路径的起点 $x_{init} \in X_{free}$,目标点 $x_{goal} \in X_{free}$,机器人路径由连续函数 $s:[0,1] \rightarrow \mathbb{R}^n$ 表示。如果对所有的 $\tau \in [0,1]$,有 $s(\tau) \in X_{free}$,且满足 $s(0)=x_{init}$, $s(1)=x_{goal}$,则可规划出一条从起点到目标点满足机器人自身约束条件的连续无碰撞路径作为问题的解。

2.2 原理介绍

RRT搜索类似于树不断生长、向四周扩散的过程。算法以路径起点 x_{init} 作为随机树 T 的根节点,树中节点 x_i 用集合 V 存储,节点间的连接用边集 E 存储,所有节点满足 $x_i \in X_{free}$ 。路径规划中,从空闲区域选取随机节点引导树的生长方向。当树中的叶子节点扩散到目标点,完成整个搜索,返回该节点到根节点的树干路径连线。算法伪代码如下:

```
Build_RRT( $x_{init}, x_{goal}, K$ )
1.  $T.init(x_{init})$ ;
2. for  $k=1$  to  $K$  do
3.    $X_{rand} \leftarrow RANDOM()$ ;
4.    $X_{near} \leftarrow NEAREST(X_{rand}, T)$ ;
5.   if  $OBS\_NOT\_FREE(X_{near}, X_{rand})$ 
6.     continue;
7.    $X_{new} \leftarrow NEW\_STATE(X_{near}, X_{rand}, u)$ ;
8.    $V \leftarrow T.add\_vertex(X_{new})$ ;
9.    $E \leftarrow T.add\_edge(X_{near}, X_{new})$ ;
```

```
10. if  $dis[X_{new}, x_{goal}] < u$ 
11.   Return  $T$ ;
```

算法在第1~2行初始化随机树,满足最大迭代次数下,进入循环。

第3~7行产生新节点, $RANDOM$ 函数在空闲区域中生成随机节点 X_{rand} 。 $NEAREST$ 函数利用欧式距离选择树节点中离 X_{rand} 最近的节点 X_{near} 。若 X_{near} 与 X_{rand} 的连线上存在障碍物,则判断条件终止当前循环,进入新一轮循环。 NEW_STATE 函数从 X_{near} 与 X_{rand} 的连线方向上扩展固定步长 u ,得到新节点 X_{new} 。节点扩展过程如图1所示。




图1 RRT算法扩展步骤

第8~9行将生成的新节点与新边添加至随机树。

第10~11行给出算法终止条件。若新节点与目标点的欧式距离小于固定步长或者已经抵达目标点,则返回随机树 T 。若达到最大迭代次数 K ,终止算法并退出。

返回随机树后,标记目标点与循环遍历得到的父节点,直到树根节点被标记。此时,算法从随机树中找到一条由标记节点连接的起点至目标点间无碰撞的可行路径。

2.3 性能分析

表1将RRT与常见的机器人路径规划算法进行比较^[3-5],分析算法存在的优缺点以及适用范围。

从表1可知,RRT适用范围广,节点随机性使算法在复杂环境中具有灵活的搜索能力。算法结构简单,容易添加非完整约束条件,可作为路径规划模块整合到各种规划系统中。随机树扩散规模类似Voronoi图,初期

表1 RRT与其他类型的机器人路径规划算法比较

算法	优点	缺点	适用范围
RRT算法	参数少,结构简单,搜索能力强,易与其他算法相结合,能解决高维空间与复杂约束问题	算法后期节点利用率低,计算量偏大,路径不稳定	全局离线以及局部在线路径规划,高维度、复杂环境下的路径规划
概率路线图(PRM)算法	解决高维空间路径规划问题,路径重用性强	复杂环境下的搜索效率低	离线的全局路径规划,高维度环境下的路径规划
A*算法	搜索能力强,能收敛到全局最优路径	计算复杂度依赖网格分辨率完整性,不适合高维环境路径规划	离线的全局路径规划
粒子群(PSO)算法	算法简洁,易于实现,具有记忆性,收敛速度快	容易陷入局部最优解,不适用于局部以及高维环境的路径规划	离线的全局路径规划
神经网络算法	优秀的学习能力,鲁棒性强,易与其他算法结合	高度依赖学习环境,泛化能力差	经过离线训练后的全局路径规划

尽量偏向环境四周,将环境分成较大的空闲区域再进行细分,对不同区域的随机采样点,总有树中的最近节点与之对应。此外,算法具备**概率完备性**,在时间允许条件下,总能找到从起点到目标区域的可行路径。

3 算法发展综述

概率完备性
分辨率完备性

RRT在路径规划领域取得较大的进展,但算法仍存在在节点利用率低、路径不稳定等不足。现有文献对RRT的改进主要从单向随机树扩展、多向随机树扩展及其他方面展开。其中,单向随机树扩展作为一种数据结构,用于多向随机树扩展以及其他改进;提高整体计算效率,拓展算法应用范围,是改进算法的研究基础。

3.1 单向随机树扩展

单向随机树扩展以路径起点作为随机树根节点,整体结构简单,建模方便,解决了“维度爆炸”导致的空间路径规划难题,能良好地用于机械臂、四旋翼等高维度完整约束的机器人路径规划。改进算法主要从节点采样优化与步长优化两方面提高路径质量,为后续算法的改进提供理论基础。

3.1.1 节点采样优化

Urmson等人提出具有节点偏置概率的hRRT(Heuristically RRT)算法^[7]。该算法采用启发式搜索计算节点偏置概率,设定概率上限,符合条件的节点偏向目标扩展。对满足启发式的多个节点不能选取最低成本节点扩展的缺陷,在hRRT算法基础上结合最近邻搜索,提出邻域节点扩展的IkRRT(Iterative k -Nearest Neighbor RRT)算法与最佳邻节点扩展的BkRRT(Best of k -Nearest Neighbors)算法。不同环境下的实验证明,BkRRT路径平均长度更低,但相应的搜索时间更长,且容易陷于局部最优。

Kalisiak等人提出RRT-blossom^[8]算法,利用回归约束函数产生新节点,使随机树前期降低重复区域搜索概率,尽可能探索未知环境,避免搜索空间的局部最优。约束函数淘汰的节点被设为休眠状态,当随机树通过约束函数形成稀疏的全局随机树后,若没找到目标区域,此时休眠节点进行更小区域搜索,保证概率完整性。上述算法通过偏置采样策略选取节点扩展,提高算法生成路径质量,但算法的结构限制了节点的自适应扩展,虽然保证了算法的高效性,却无法生成当前最优路径。

对于RRT面临的不足,Frazzoli等人提出具有渐进最优性(最短距离)的RRT*^[9]算法,在RRT节点扩展基础上添加随机几何图与剪枝优化理论,确保随机树的节点都能收敛到当前最优值。**RRT*标记每个节点到根节点的距离,记为节点权值**,在以 X_{new} 为圆心,当前随机树节点总数量决定半径 R 的邻域内,计算 X_{new} 与邻域内所有节点连接后的权值大小。删除 X_{new} 与原父节点 X_{near} 的连线,找到使 X_{new} 权值最小的节点 X_{min} 作为新

的父节点。若邻域内存在节点的权值大于当前 X_{new} 的权值与到该节点的距离之和,以当前 X_{new} 节点作为父节点,确保邻域内的节点权值总是当前最优。整体优化过程如图2所示。RRT*能收敛到全局最优解。但是当节点数量过于庞大时,算法的内存消耗与计算量会呈指数上升^[10],降低算法运行速度,不适用于实时性强的环境。因此,提高优化路径的有效节点数量,降低节点内存消耗,是RRT*算法的主要改进方向。




图2 RRT*节点扩展过程示意图

Nasir等人提出具有智能采样与路径优化功能的RRT*-smart^[11]算法,解决RRT*收敛缓慢问题。算法初始路由RRT*生成,删除冗余节点后,将当前路径上接近障碍物的节点设为信标点,在其周围偏置采样,优化障碍物边缘路径,降低整体路径长度。定义偏置率 B 偏向信标附近生成采样点,每当获得更小长度的新路径时,再次优化路径并识别新信标。然而,智能采样注重收敛速度而牺牲随机探索特性,可能会丢失更优解。而且不同的环境下需人为地调整偏置率,算法自适应性需要提高。

Arsalan等人提出RRT#^[12]解决RRT*收敛缓慢问题。

该算法主要通过探测与利用两步骤完成路径优化。探测过程完成随机树扩展。利用过程通过全局重规划选取随机树中低权值的节点,生成局部的最短路段作为部分全局路径。RRT#在每次迭代中都会更新低权值节点,按优先级对最短路段排序,实现全局路径的快速收敛。

Gammell等人提出直接采样的Informed-RRT*^[13]。算法直接限制采样区间提高整体收敛速度。首先由RRT*求出初始路径长度,进而生成由椭圆性质定义的启发式有限椭圆采样子集。生成路径长度视作椭圆长轴,两端点直线距离视作短轴,从椭圆中选取采样节点。启发式椭圆采样子集面积随着路径长度降低而减小,经过多次路径优化后,能选取当前环境的最优路径。

3.1.2 步长优化

刘成菊等人提出基于RRT的变步长搜索^[14]。算法添加目标引力变量,随机树扩展受到随机节点与目标点引力变量共同作用。调整引力系数获得不同长度的步长,基于大步长快速扩展,小步长收敛路径的思想,提高搜索效率。针对动态障碍物出现在生成路径中导致路径规划失败问题,文中设置路径缓存及重规划^[15],快速

生成避开障碍物的新路径,提高整体节点利用率。Wang 等人在无人机巡航^[16]中采用变步长 RRT 生成初始路径,删除冗余节点后,结合三角不等式性质,优化后的节点偏向障碍物顶点,获得当前最短的同伦路径。

3.2 多向随机树扩展

多向随机树以单向随机树作为基本树结构进行扩展,在工作空间中构造多个随机树根节点,优化随机树之间的连接方式,提高路径规划效率。改进算法降低工作空间中细小区域搜索概率,减少采样节点数量,随机搜索性能强,更适合狭窄区域或复杂环境下的路径规划。

3.2.1 双向随机树

Lavalle 等人提出双向随机树(Bidirectional RRT, bi-RRT)^[17]用于高维度机械臂路径规划。算法以起点与目标点为树根节点生成两棵树进行扩展,目标点随机树以起点随机树生成的新节点为扩展方向,直到两棵树的叶子节点互相连接。RRT-connect^[18]在 bi-RRT 上引入贪婪扩展思想,在目标点随机树中设置循环扩展,加快双向随机树节点连接速度。Akgun 等人在此基础上结合 RRT* 提出渐进最优的 B-RRT*(Bidirectional RRT*)^[19],以 RRT* 代替 RRT 扩展起点随机树。找到初始路径后,设定采样约束减少无效节点,用局部偏置优化路径上的节点至局部最优。但是,算法在连接节点时仍需执行 RRT* 全部操作,并在每次迭代时连接随机树,产生大量的计算开销。

Jordan 等人提出多种基于启发式技术的改进 B-RRT*^[20]算法。结合 RRT-connect 与启发式思想的快速收敛性,降低节点扩展过程的计算量,提高总体收敛速度。但启发式在一定程度上限制了算法原有的探索、采样策略等性质。Qureshi 与 Ayaz 提出智能双向搜索的最优算法 IB-RRT*(Intelligent Bidirectional RRT*)^[21],专用于复杂环境搜索。算法使用智能样本插入的启发式技术,舍弃 RRT-connect 的贪婪策略,通过随机节点邻域填充或者最近节点权值排序选择扩展节点。王全等人^[22]提出平滑路径的拼接算法,优化随机树间的连接方式。给定初始方向及运动系统的最小半径等约束条件,生成的圆弧路径能满足非完整约束系统的路径规划。Burget 等人提出满足任务约束的双向搜索算法 BI-RRT*(Bidirectional Informed RRT*)^[23]。算法结合 Informed-RRT* 与 B-RRT* 特点,使用双随机树生成初始路径,解决收敛速度慢的缺陷,为 Informed-RRT* 提供更多椭圆子集采样优化时间。结果表明,该算法比 B-RRT* 算法更高效。

Yi 等人提出基于双向 RRT* 的同伦变体算法 HARRT*(Homotopy Aware RRT*)^[24]。算法通过人为干涉来规划从一个拓扑空间到另一个拓扑空间的路径。这种方法解决了搜索和救援、军事中的人机互动的规划问题。通过案例研究从理论上证明了所提方法的有效性。

3.2.2 多向随机树

Rodriguez 等人在 OB-RRT(Obstacle Based RRT)^[25]中通过狭窄区域建立根节点,让随机树更快地寻找到可行路径。刘多能结合主观意识,提出人工导引 RRT^[26]算法,在环境中人为设定多个随机树根节点,引导随机树通过搜索困难的狭窄区域,优化节点连接过程。

Otte 等人提出了 C-Forest(Coupled Forest of Random Engrafting Search Trees)算法^[27],通过并行计算寻找最优路径。算法在每个 CPU 上生成单随机树,并通过椭圆子集寻找单随机树最优解决方案。多棵随机树通过 T-CPU 通信共享最优解决方案,选取比较后的不同位置的探索节点,满足多随机树扩展特性。算法以当前最短路径为基础,进行新一轮的优化。并行多随机树在整体上降低了收敛至最优的时间。

3.3 RRT 其他方面改进

RRT 的改进方式具有多样性,除了对自身结构进行优化外,也结合其他方面提高路径质量与整体收敛速度,生成满足非完整约束方程的机器人系统路径,扩展算法的应用空间。

3.3.1 曲率平滑后处理

平滑的可执行路径是非完整约束机器人路径规划的重要条件,RRT 因计算高效、耗时少而在非完整约束系统中得到广泛的应用。徐娜等人^[28]结合非完整约束方程与目标偏置的 RRT 算法,将欧式距离换成对角线距离,提高运算速度。对生成的初始路径进行曲率平滑的后处理操作,产生满足约束的可行路径,使用车辆、平板、单轮车等非完整约束模型进行模拟,验证了路径的可行性。杜明博等人提出连续曲率的 RRT 算法(Continuous Curvature RRT, CC-RRT)^[29],考虑环境与车辆最大曲率约束,通过剪枝函数与 B 样条曲线结合的后处理方式,生成满足约束的可行路径。Yang 等人提出无人机路径平滑算法 SRRT(Smooth-Path RRT)^[30],以随机树路径的夹角为连续曲率的唯一信息,通过三次 B 样条曲线生成满足无人机最小曲率半径约束的可行路径。

3.3.2 引导域偏置采样

与启发式的目标点偏置采样相比,引导域偏置采样需要提前生成优化随机树扩展的引导区域,再通过 RRT 进行路径扩展。GA-RRT(Guiding-Area RRT Based on A*)^[31]以 A* 路径为引导域,先完成低分辨率下的 A* 路径规划,生成次优路径。在当前路径基础上,随机树以一定概率选取当前路径周边节点,减少无效节点。实验证明,优化后的路径适合车辆运行且规划时间短。文献[32]将高斯分布模型作为引导区域,设定概率密度函数偏向高斯曲线上的离散节点。仿真结果显示,通过引导域扩展 RRT 在路径质量上相对于基本 RRT 算法都有很大改进。此外,动态限制域的 Informed-RRT*^[13]、IB-RRT^[21]等,也是基于椭圆子集引导域偏置的采样算法。

3.3.3 结合智能算法采样

RRT 搜索过程中,后期节点扩展会产生大量的冗余节点。因此,将 RRT 与智能算法结合,通过训练得到具有记忆性的节点,提高不同环境模型下的路径规划速度。Cheng 等人^[33]用自学习方法提高节点质量来改善整体路径,在 RRT 搜索过程中用扩展函数训练环境模型。设定节点环境约束标准,离障碍物远的节点约束性小,近的约束性大,删除约束性大的节点。随机树经过多次搜索后,节点具有记忆性,路径规划质量更好,搜索速度更快。王全等人结合强化学习^[34],采用基于在线学习策略的 Sarsa 方法评价节点质量。根据评价值的变化设定奖励或惩罚措施,提高节点对环境的感知度,确保新节点扩展只与当前节点到树根节点的分支有关,减少整体带来的影响。

Shiarlis 等人提出基于 RRT* 扩展的快速学习随机树算法 (Rapidly-Exploring Learning Trees, RLT*)^[35]。针对反向强化学习 (Inverse Reinforcement Learning, IRL) 中路径规划开销大、计算复杂的问题,定义缓存方案,降低 RLT* 计算成本。Higueras 等人利用完全卷积神经网络 (Fully Convolutional Neural Networks, FCN)^[36],以无监督学习方式学习路径规划任务,避免成本函数的显式表达,训练后的 FCN 指导 RRT* 扩展完成实际的路径搜索。实验显示,FCN-RRT* 比 RLT* 取得了更好结果。Qureshi 等人提出基于 DNN 的运动规划网络 (Motion Planning Networks, MPNet)^[37],以双向随机树扩展产生的路径作为迭代对象。算法能较好地解决高维问题,解决神经网络在未知环境中泛化能力差的不足。Ichter 等人^[38]提出自学习的非均匀节点采样分布。先由离线学习得出可能存在的最优路径区域,再执行采样算法,将采样节点集中在该区域进行偏置采样,提高路径规划速度。

Melchior 等人提出基于粒子节点搜索的 RRT 算法 (Particle RRT, PRRT)^[39]。随机树节点由粒子群组成,每个粒子模拟节点扩散,求出粒子群的平均扩散概率代替单个节点扩散概率。此外,算法利用 hRRT^[7] 的目标偏向思想,提高路径质量,算法鲁棒性强。Viseras 等人将 RRT* 与蚁群算法^[40]结合,提出具备学习能力的启发式随机树框架。实验证明,具有启发式的随机树与蚁群算法结合优于 RRT* 规划的效果。

3.3.4 优化数据结构

RRT 的树结构存储方式具有多种数据结构变体。Yershova 等人^[41]提出动态 KD-tree 的存储结构,降低新节点搜索最近邻节点的计算量,解决 RRT 节点不断变化而重构 KD-tree 的低效性。动态 KD-tree 每次搜索产生对数时间开销,算法整体效率高。Sandstrom 等人^[42]使用拓扑邻滤波对空间区域的邻节点集合进行处理,求得显著减少的邻节点集。作为一种采样预处理方法,它可与 KD-tree、散列表等存储结构结合,提高算法规划速度。

3.3.5 实时路径规划

实际工作的机器人在未知或动态环境中可能会面临各种突发情况,导致规划路径不可用,而实时路径规划旨在重新规划可行路径,提高算法鲁棒性。张捍东等人^[43]将改进的 RRT 与滚动窗口模型结合,处理未知环境的实时路径规划。机器人在基于传感器视距的窗口内未发现障碍物时,按照窗口内的规划路径前进;发现障碍物后,选取合适的子目标点重新规划路径规避障碍物。刘新宇等人^[44]在未知环境中采用聚类算法对可见区域内环境的复杂程度进行判别,生成自适应的局部规划区域。算法降低区域中障碍物数量与碰撞检测的计算量,提高整体收敛速度,具有良好的环境适应能力。Pimentel 等人^[45]提出有效探索未知环境的 ID-RRT (Information-Driven RRT) 算法。算法同时从多个可扩展节点中选取能探索更多未知区域信息的子目标点扩展,并记录环境信息。同时让机器人执行规划的子路径段,防止环境更新影响子目标点位置。相对其他局部路径规划,ID-RRT 能对全局环境快速建模,避免产生局部最优路径。Naderi 等人^[46]提出动态环境的实时路径规划算法 RT-RRT* (Real Time RRT*)。算法保留整棵随机树,能快速生成任何目标区域的可行路径,实时性强。树根节点随着生成路径移动到目标区域而不删除原有节点,同时建立以根节点为圆心的移动邻域,增加邻域内的采样节点数量,重连随机树节点至当前最优,用来实时优化邻域内的可行路径,提高动态环境的避障速度。

3.4 改进算法小结

表 2 对具有代表性的算法进行简要归纳,列举算法采样方式,分析存在的优缺点以及适用场景。

4 算法的研究方向与挑战

RRT 经历长时间发展,取得了大量的研究成果。然而,优化后的路径与最优路径仍有一定差距。主要原因在于改进的 RRT* 算法需要不断调整步长以提高路径精度,生成最优路径所消耗的内存资源及计算时间呈指数增长,不适用于实际应用的机器人系统。此外,环境中的不规则障碍物区域采样、机器人的传感器精度、路面的凹凸性等因素也会影响路径质量。本文对目前算法面临的问题进行总结,并对未来研究方向提出几点建议。

(1) 提高节点利用率

RRT 及 RRT* 生成大量节点避免产生局部最优路径或搜索失败。算法通过均匀采样探索整个区域,树中大部分探索节点离生成路径的优化区域远,优化路径的概率小。此外,树的概率完整性使这些节点不断添加无效分支,增加计算时间。改进算法通过路径重规划^[15,46-47],利用已有探索节点快速形成新路径;设定智能偏置采样^[7]、启发式采样^[7,20]等约束条件,选取有利于路径优化

表2 改进算法采样方式及优缺点

算法名称	采样方式	算法优点	存在的缺陷	算法适用场景
HRRT ^[7]	启发式采样	选取启发式成本低的目标偏置节点扩展	牺牲计算时间,且容易陷入局部最优	仿真环境的全局路径规划
RRT_blossom ^[8]	约束偏置采样	通过约束方程避免局部最优,提高整体搜索速度	约束方程单一,大空间的搜索环境,效率低	仿真环境的局部及全局路径规划
RRT* ^[9]	均匀采样	算法具备渐进最优性,在时间条件允许下,能收敛到最优路径	节点计算量大,内存消耗大	仿真环境的全局最优路径规划
RRT*-smart ^[11]	智能偏置采样	定义信标点与偏置比的启发式算法实现智能采样搜索,加快算法的收敛速度	收敛速度与路径质量不能同时取得最优,不同环境需手动调节偏置比,自适应性差	仿真环境的全局最优路径规划
RRT# ^[12]	均匀采样	引入全局重规划,排序选取最低权值节点,快速收敛至全局最优路径	最低权值节点只能在生成新路径时获得,未设置基于最低权值节点的启发式采样	机械臂、四旋翼等完整约束系统的全局最优路径规划
Informed-RRT* ^[13]	区域直接采样	使用椭圆区域限制节点采样范围,减少无效节点,提高最优路径收敛速度	初始椭圆子集由RRT*全局搜索生成,整体时间开销大	仿真环境的全局最优路径规划,狭窄区域的最优路径规划
RRT-connect ^[18]	启发式采样	通过贪婪搜索连接两棵随机树,降低采样节点数量,提高收敛速度	路径非最优,只适用于完整约束下的机器人路径规划	机械臂、四旋翼等完整约束系统的全局路径规划
改进B-RRT* ^[20]	启发式采样	使用多种启发式策略,能在不同条件下提高双向RRT*的收敛速度	多种启发式采样提高整体计算量,限制算法自身的搜索特性	仿真环境的全局最优路径规划
HARRT* ^[24]	启发式采样	结合RRT*和同伦算法,提出人机交互规划器,提高规避特定障碍物下同伦路径规划速度	算法的计算效率与路径质量不能同时取得最优	仿真环境的全局同伦最优路径规划
CC-RRT ^[29]	均匀采样	使用B样条曲线优化生成路径,适用于非完整约束的路径搜索	当前算法只适用于低速运动车辆的约束环境	无人车、叉车等平面非完整约束系统的全局路径规划
SRRT ^[30]	均匀采样	使用少量参数生成可行路径,降低计算复杂度,适合无人机等实时性强的路径规划应用	未考虑传感器精度、风力、其他未建模的因素影响	无人机、直升机、水下机器人、医疗机器人等复杂空间中非完整约束系统的全局路径规划
RLT* ^[35]	均匀采样	利用IRL框架学习RRT*扩展过程,设计缓存方案降低计算成本,收敛速度快	IRL学习框架整体开销大,计算复杂,需进一步优化	工业机器人等稳定性要求高的最优路径规划,狭窄区域的最优路径规划
PRRT ^[39]	目标偏置采样	用粒子群的平均扩散概率代替节点扩散概率,适合未知环境搜索,算法鲁棒性强	节点扩展取粒子群的平均扩散概率,实时性差	未知环境下崎岖路面或障碍物多的局部路径规划
KD-RRT ^[41]	均匀采样	使用KD-tree数据结构存储RRT的生成节点,减少最近邻搜索计算量	KD-tree重构时间较长,需进一步优化RRT的存储结构	仿真环境的全局路径规划
ID-RRT ^[45]	均匀采样	提高未知环境下信息采集速度与路径稳定性,避免局部最优路径	传感器精度要求高,单机器人在未知环境的信息采集速度慢	未知环境下的移动机器人局部路径规划
RT-RRT* ^[46]	均匀采样	实时路径规划性能强,适合动态环境的路径规划	只能用于有界环境搜索,内存消耗大	动态环境下的实时路径规划

的节点进行扩展;利用直接采样^[13,48]限制采样区间,确保新的采样节点总在路径优化区域内。但是,现有改进算法中,路径重规划速度受到随机树节点数量限制,不同约束条件的采样算法需根据环境人为调节条件参数,自适应能力不足。因此,进一步提高路径优化中节点利用率,生成更智能的算法,值得深入研究与讨论。

(2)改进最近邻搜索算法

随机树经过均匀采样搜索,寻找最近邻节点的计算量会随着节点指数增长而增长,直接降低了算法收敛速度。最近邻搜索算法作为限制RRT收敛速度的瓶颈,受到了研究者的高度重视。改进算法结合KD-tree^[39]、散

列表^[42]等高效的数据结构存储节点,优化最近邻节点的选取方式,避免通过欧式距离寻找邻节点而产生复杂的计算量。但是,改进的数据结构存在添加节点时间长,节点数量大导致资源消耗大,后期维护困难等不足。以后的研究中,在树结构的基础上使用其他技术生成更快的搜索算法,降低最近邻节点连接成本,有助于进一步提高算法收敛速度。

(3)优化狭窄区域采样

RRT均匀采样性质降低了狭窄区域选取随机节点的概率。作为采样算法的研究难点,很少有算法专门解决狭窄区域的最优路径。现有改进算法主要通过直接

采样解决狭窄区域渐进收敛问题,如 Informed-RRT*[¹³]与 RABIT*[⁴⁸],通过不断减少采样区间,提高路径中的狭窄区域采样概率。此外,在狭窄区间过多的环境中,受障碍物影响,算法容易生成当前同伦最优路径,导致最终路径不唯一。使用深度学习[^{33,35,38}]离线训练,得到经过筛选的高回报值节点,能优化最终路径稳定性。现阶段应进一步提高上述算法性能,并着重研究实际机器人系统在狭窄区域的优化过程。

(4) 优化非完整约束方程

非完整约束机器人的运动方程复杂,计算量大。常见的非完整约束机器人路径规划先通过 RRT 算法求得可行路径,再采用曲率平滑后处理生成满足运动方程约束的路径[²⁸⁻³⁰]。然而,实际规划中路径目标更新快,后处理计算量大。非完整约束的运动方程需要考虑以下问题:优化运动方程,减少方程计算量;平衡实时性强的非完整约束机器人中曲线计算效率与路径精度;选取适合狭窄区域的非完整约束机器人度量准则,提高狭窄区域下的路径稳定性。未来对非完整约束的研究应着重解决实际的动力学问题,并进一步优化路径平滑度。

5 结束语

RRT 算法具有高效的随机扩展性,可快速生成可行路径,为高维且复杂的机器人路径规划问题提供了一种新的解决方案,并取得了良好的进展。虽然改进的 RRT 算法在路径质量、计算时间上取得显著的成果,但仍未达到理论上的最优结果。对 RRT 进一步探索,使其有更广泛的应用空间,对机器人路径规划具有重要的研究意义。

参考文献:

- [1] 余卓平,李奕姗,熊璐.无人车运动规划算法综述[J].同济大学学报(自然科学版),2017,45(8):1150-1159.
- [2] 李磊,叶涛,谭民,等.移动机器人技术研究现状与未来[J].机器人,2002,24(5):475-480.
- [3] 冯来春.基于引导域的参数化 RRT 无人驾驶车辆运动规划算法研究[D].合肥:中国科学技术大学,2017.
- [4] 张广林,胡小梅,柴剑飞,等.路径规划算法及其应用综述[J].现代机械,2011(5):85-90.
- [5] Noreen I, Khan A, Habib Z. Optimal path planning using RRT* based approaches: a survey and future directions[J]. International Journal of Advanced Computer Science and Applications, 2016, 7(11): 97-107.
- [6] Lavalley S. Rapidly-exploring random trees: a new tool for path planning[R]. Iowa State University, 1998.
- [7] Urmson C, Simmons R. Approaches for heuristically biasing RRT growth[C]//2003 IEEE/RSJ International Conference on Intelligent Robots & Systems, 2003: 1178-1183.
- [8] Kalisiak M, Panne M V D. RRT-blossom: RRT with a local flood-fill behavior[C]//IEEE International Conference on Robotics and Automation, 2006: 1237-1242.
- [9] Karaman S, Frazzoli E. Sampling-based algorithms for optimal motion planning[J]. The International Journal of Robotics Research, 2011, 30(7): 846-894.
- [10] Adiyatov O, Varol H A. Rapidly-exploring random tree based memory efficient motion planning[C]//2013 IEEE International Conference on Mechatronics & Automation, 2013: 354-359.
- [11] Nasir J, Islam F, Malik U, et al. RRT*-smart: a rapid convergence implementation of RRT*[J]. International Journal of Advanced Robotic Systems, 2013, 10(4).
- [12] Arslan O, Tsiotras P. Use of relaxation methods in sampling-based algorithms for optimal motion planning[C]//2013 IEEE International Conference on Robotics and Automation, 2013: 2421-2428.
- [13] Gammell J D, Srinivasa S S, Barfoot T D. Informed RRT*: optimal sampling-based path planning focused via direct sampling of an admissible ellipsoidal heuristic[C]//2014 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2014: 2997-3004.
- [14] 刘成菊,韩俊强,安康.基于改进 RRT 算法的 RoboCup 机器人动态路径规划[J].机器人,2017,39(1):8-15.
- [15] Ferguson D, Kalra N, Stentz A. Replanning with RRTs[C]//2006 IEEE International Conference on Robotics and Automation, 2006: 1243-1248.
- [16] Wang C, Meng M Q. Variant step size RRT: an efficient path planner for UAV in complex environments[C]//2016 IEEE International Conference on Real-Time Computing and Robotics, Angkor Wat, 2016: 555-560.
- [17] Lavalley S M, Kuffner J J. Randomized kinodynamic planning[J]. International Journal of Robotics & Research, 1999, 15(5): 378-400.
- [18] Kuffner J J, Lavalley S M. RRT-connect: an efficient approach to single-query path planning[C]//2002 IEEE International Conference on Robotics and Automation, 2002: 995-1001.
- [19] Akgun B, Stilman M. Sampling heuristics for optimal motion planning in high dimensions[C]//2011 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2011: 2640-2645.
- [20] Jordan M, Perez A. Optimal bidirectional rapidly-exploring random trees: MIT-CSAIL-TR-2013-021[R]. CSAIL MIT, 2013.
- [21] Qureshi A H, Ayaz Y. Intelligent bidirectional rapidly-exploring random trees for optimal motion planning in complex cluttered environments[J]. Robotics and Autonomous Systems, 2015, 68: 1-11.
- [22] 王全,王维,李焱,等.基于混合策略的轮式机器人路径规划方法[J].计算机工程与应用,2014,50(4):45-49.

- [23] Burget F, Bennewitz M, Burgard W. BI2RRT*: an efficient sampling-based path planning framework for task-constrained mobile manipulation[C]//2016 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2016:3714-3721.
- [24] Yi D, Goodrich M A, Seppi K D. Homotopy-aware RRT*: toward human-robot topological path-planning[C]//2016 11th ACM/IEEE International Conference on Human-Robot Interaction, 2016:279-286.
- [25] Rodriguez S, Tang X, Lien J M, et al. An obstacle-based rapidly-exploring random tree[C]//2006 IEEE International Conference on Robotics and Automation, 2006: 895-900.
- [26] 刘多能. 基于人机智能融合的移动机器人路径规划方法研究[D]. 长沙:国防科学技术大学, 2011.
- [27] Otte M, Correll N. C-Forest: parallel shortest path planning with superlinear speedup[J]. IEEE Transactions on Robotics, 2013, 29(3): 798-806.
- [28] 徐娜, 陈雄, 孔庆生, 等. 非完整约束下的机器人运动规划算法[J]. 机器人, 2011, 33(6): 666-672.
- [29] 杜明博, 梅涛, 陈佳佳, 等. 复杂环境下基于RRT的智能车辆运动规划算法[J]. 机器人, 2015, 37(4): 443-450.
- [30] Yang K, Sukkarieh S. 3D smooth path planning for a UAV in cluttered natural environments[C]//2008 IEEE/RSJ International Conference on Intelligent Robots and Systems, Nice, 2008: 794-800.
- [31] 冯来春, 梁华为, 杜明博, 等. 基于A*引导域的RRT智能车辆路径规划算法[J]. 计算机系统应用, 2017, 26(8): 127-133.
- [32] 宋晓琳, 周南, 黄正瑜, 等. 改进RRT在汽车避障局部路径规划中的应用[J]. 湖南大学学报(自然科学版), 2017, 44(4): 30-37.
- [33] Cheng P, Lavalle S M. Reducing RRT metric sensitivity for motion planning with differential constraints[D]. Iowa State University, 2001.
- [34] 王全. 基于RRT的全局路径规划方法及其应用研究[D]. 长沙:国防科学技术大学, 2014.
- [35] Shiarlis K, Messias J, Whiteson S. Rapidly exploring learning trees[C]//2017 IEEE International Conference on Robotics and Automation, 2017: 1541-1548.
- [36] Pérez-Higueras N, Caballero F, Merino L. Learning human-aware path planning with fully convolutional networks[C]//2018 IEEE International Conference on Robotics and Automation, 2018: 1-6.
- [37] Qureshi A H, Simeonov A, Bency M J, et al. Motion planning networks[J]. arXiv: 1806.05767, 2018.
- [38] Ichter B, Harrison J, Pavone M. Learning sampling distributions for robot motion planning[C]//2018 IEEE International Conference on Robotics and Automation, 2018: 7087-7094.
- [39] Melchior N A, Simmons R. Particle RRT for path planning with uncertainty[C]//2007 IEEE International Conference on Robotics and Automation, 2007: 1617-1624.
- [40] Viseras A, Losada R O, Merino L. Planning with ants: efficient path planning with rapidly exploring random trees and ant colony optimization[J]. International Journal of Advanced Robotic Systems, 2016, 13(5): 1-16.
- [41] Yershova A, LaValle M S. Improving motion-planning algorithms by efficient nearest-neighbor searching[J]. IEEE Transactions on Robotics, 2007, 23(1): 151-157.
- [42] Sandstrom R, Bregger A, Smith B, et al. Topological nearest-neighbor filtering for sampling-based planners[C]//2018 IEEE International Conference on Robotics and Automation, 2018: 3053-3060.
- [43] 张捍东, 陈阳, 吴玉秀, 等. 未知环境下移动机器人实时路径规划[J]. 计算机工程与应用, 2018, 54(19): 140-146.
- [44] 刘新宇, 谭力铭, 杨春曦, 等. 未知环境下的蚁群-聚类自适应动态路径规划[J]. 计算机科学与探索, 2019, 13(5): 846-857.
- [45] Pimentel J M, Alvim M S, Campos M F M, et al. Information-driven rapidly-exploring random tree for efficient environment exploration[J]. Journal of Intelligent & Robotic Systems, 2017, 91(5): 1-19.
- [46] Naderi K, Rajamäki J, Hämmäläinen P. RRT-RRT*: a real-time path planning algorithm based on RRT*[C]//8th ACM SIGGRAPH Conference on Motion in Games, 2015: 113-118.
- [47] Zucker M, Kuffner J, Branicky M. Multipartite RRTs for rapid replanning in dynamic environments[C]//2007 IEEE International Conference on Robotics and Automation, 2007: 1603-1609.
- [48] Choudhury S, Gammell J D, Barfoot T D, et al. Regionally accelerated batch informed trees (RABIT*): a framework to integrate local information into optimal path planning[C]//2016 IEEE International Conference on Robotics and Automation, 2016: 4207-4214.